Projeto Final - Dados e IA - 2025.02

Nome: Isis Vitória Souza Abreu
E-mail: ivsa@cesar.school
Dataset: https://www.kaggle.com/datasets/kandij/diabetes-dataset

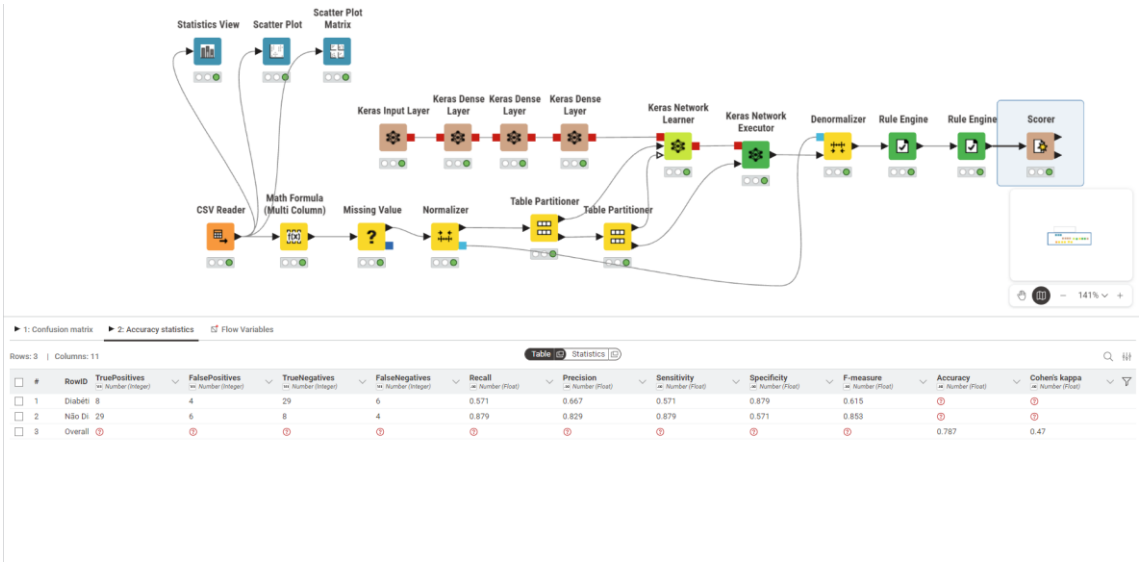

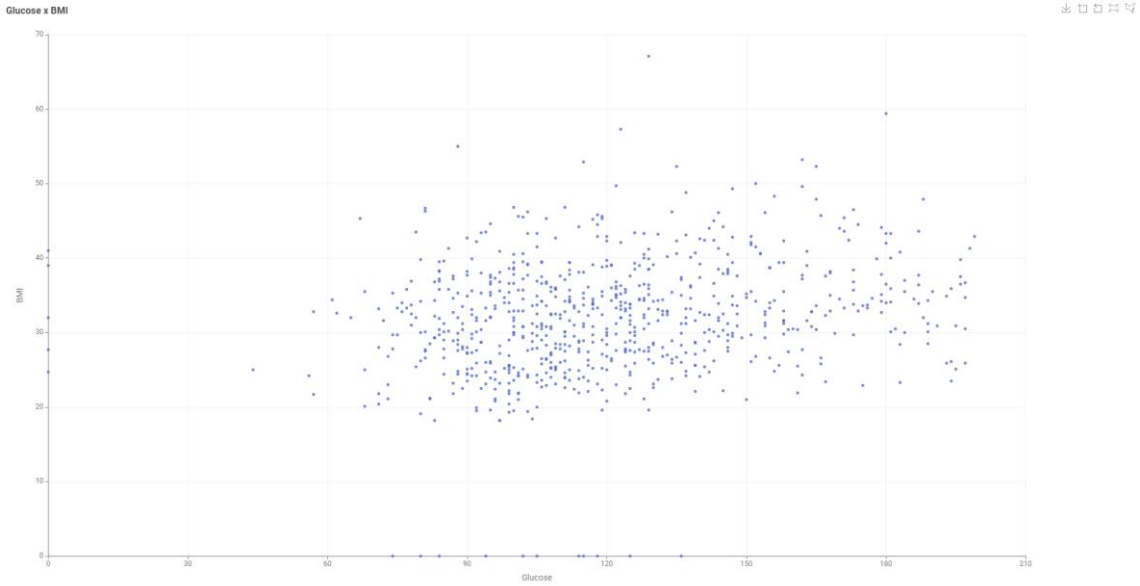

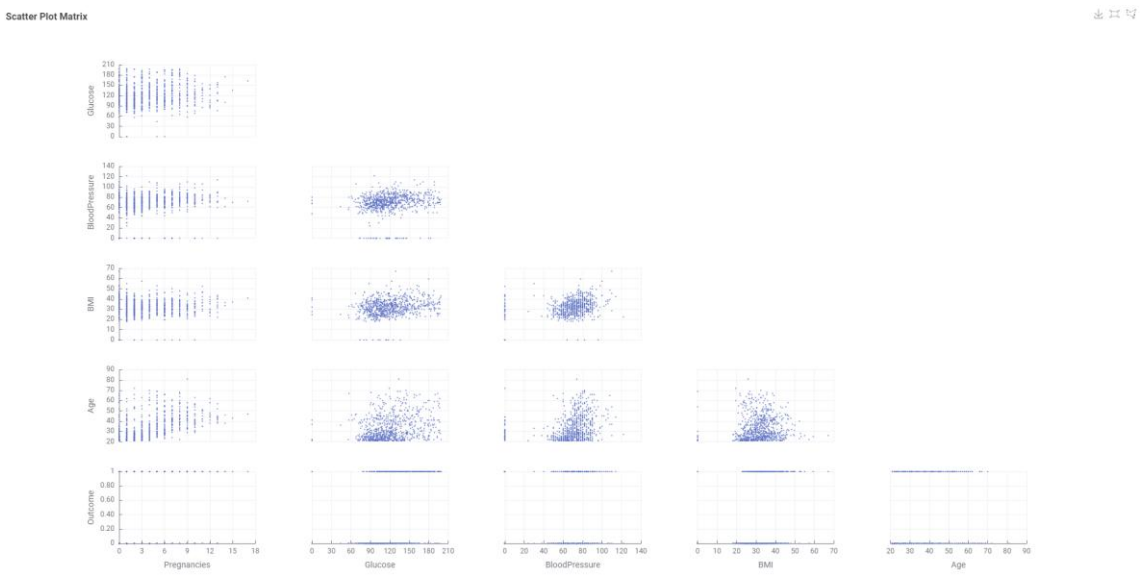

Durante o desenvolvimento deste projeto, foi possível compreender melhor todo o processo de construção de um modelo de aprendizado de máquina, desde a exploração inicial do dataset até o treinamento e avaliação do modelo. Inicialmente foram utilizadas ferramentas de visualização, como ***Statistics View***, ***Scatter Plot*** e ***Scatter Plot Matrix***, para analisar a distribuição dos dados e identificar possíveis relações entre as variáveis do dataset.

Inicialmente, construí o modelo padrão aprendido em sala de aula utilizando a seguinte sequência (**CSV Reader, Normalizar, 2 Table Partitioner, Keras Input, 3 Keras Dense, Keras Network Leaner, Keras Network Executor, Denomalizer e Score**).

Ao tentar utilizar o nó **Score**, precisei ajustar o limiar de decisão das probabilidades geradas pela rede neural para converter os valores em classes utilizando o **Rule Engine**. Após isso, foi possível calcular métricas como *accuracy* e gerar a matriz de confusão.

Inicialmente o modelo apresentava uma *accuracy* em torno de **0,70**, fiz ajustes nos parâmetros da rede neural para melhorar os resultados, como a alteração do **learning rate** do **Adam de 0.01 para 0.001**, aumento do número de **epochs para 100**, e redução do **batch size (training e validation) para 32**. Com essas alterações a *accuracy* subiu para **0,72**.

Também foram testadas diferentes arquiteturas de rede, da seguinte forma:

- **Inicial:**
  - Input: 8
  - Camada 1: 16 neurônios, ReLU
  - Camada 2: 8 neurônios, ReLU
  - Output: 1 neurônio, Sigmoid

- **Final:**
    - Input: 8
    - Camada 1: 32 neurônios, ReLU
    - Camada 2: 16 neurônios, ReLU
    - Output: 1 neurônio, Sigmoid

Com a parametrização final, obtive 0,74 de *accuracy*. Na tentativa de melhorar o desempenho, decidi tratar valores inválidos no dataset, pois diversas colunas como **Glucose, BloodPressure, SkinThickness, Insulin e BMI** apresentavam valores iguais a 0, que na verdade representavam a ausência de informação. Para corrigir esse problema, foi necessário converter esses valores para *missing values* utilizando **Math Formula e Missing Value**, preenchendo os valores faltantes com a média das colunas, o que ajudou a reduzir o impacto de dados inválidos no treinamento do modelo e aumentar a *accuracy*, finalizando com 0,78.

De modo geral, o projeto me ajudou a consolidar conhecimentos sobre preparação de dados, seleção de atributos, ajuste de hiperparâmetros e avaliação de modelos de redes neurais, além de proporcionar maior familiaridade com as ferramentas de análise e aprendizado de máquina disponíveis no KNIME.